System-Programmierung 5: Prozess-Lebenszyklus

n|w

Ablauf heute

⅓ Vorlesung,

⅔ Hands-on,

Feedback.

Slides, Code & Hands-on: tmb.gr/syspr-5

Prozess-Lebenszyklus System Calls

Mit *fork()* erstellt ein Prozess einen neuen Prozess:
```
pid_t fork(void); // PID bzw. 0, od. -1, errno
```

exit() beendet einen Prozess, gibt Ressourcen frei:
```
void exit(int status); // status & 0377
```

wait() wartet auf eine Prozess-Zustandsänderung:
```
pid_t wait(int *status); // PID od. -1, errno
```

execve() führt ein Programm aus: `int execve(…);`

n|w

Prozess kreieren mit *fork()*

Der *fork()* System Call erlaubt einem Prozess (*Parent*) einen neuen Prozess (*Child*) zu erzeugen. Dazu wird eine fast exakte Kopie des Parent-Prozesses gemacht:
```
pid_t fork(void); // Child PID bzw. 0, oder -1
```

Der Child-Prozess bekommt Kopien der Text-, Daten-, Heap- und Stack-Segmente des Parent-Prozesses.

Ein *fork()* ist eine "Verzweigung" in zwei Kopien.

n|w

Prozess beenden mit *exit()*

Die Library Funktion *exit()* beendet einen Prozess, und gibt alle Ressourcen (Speicher, File Deskriptoren etc.) frei. Das Status Argument wird dem *wait()* Call übergeben, nachdem der Child-Prozess beendet ist:
```
void exit(int status);
```

Der C Standard definiert Konstanten für *status* Werte:
```
#define EXIT_SUCCESS 0 // siehe stdlib.h
#define EXIT_FAILURE -1 // bzw. != 0
```

n|w

Zustandsänderung abwarten mit *wait()*

Der *wait()* System Call suspendiert den Prozess, bis einer seiner Child-Prozesse *exit()* aufruft, und gibt den *status* des Child-Prozesses im Argument zurück:
```
pid_t wait(int *status); // PID oder -1, errno
```

Als *return*-Wert liefert *wait()* die Child-Prozess PID:
```
while(wait(NULL) != -1) {} // mehrere abwarten
if (errno != ECHILD) { … } // ECHILD => fertig
```

n|w

Programm ausführen mit *execve()*

Der *execve()* System Call lädt ein neues Programm in den Speicher des Prozesses. Dieser Call kommt nicht zurück. Der vorherige Programmtext wird verworfen. Daten-, Heap- & Stack-Segmente werden neu erstellt:

```
int execve(const char *filepath, // -1, errno
  char *const argv[], // letztes Element = NULL
  char *const envp[]); // letztes Elem. = NULL
```

Es gibt Varianten, allgemein *exec()* Calls genannt.

n|w

Ablauf

fork(),
execve(),
wait(),
exit().

Alternative:
$Child_A$ ruft
exit() auf.

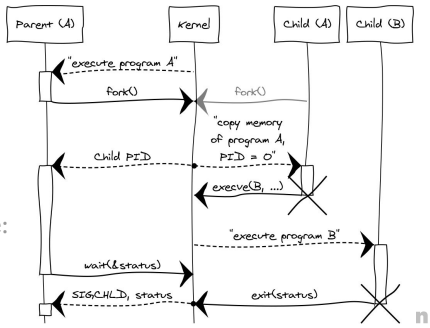

n|w

Ablauf aus Prozess Sicht

Parent:

```
A0: … // Programm A
A1: int pid = fork();
A2: if (pid == 0) {
A6: } else { // != 0
A7:   pid_c = pid;
A8:   pid = getpid();
A9:   wait(&status);
10: } // status = 0
```

Child:

```
A1: int pid = fork();
A2: if (pid == 0) {
A3:   pid = getpid();
A4:   pid_p = getppid();
A5:   execve("./B", …);
B1: … // Programm B
B2: exit(0);
```

n|w

Hands-on, 15': *fork()*

fork.!c

Schreiben Sie ein Programm *my_fork.c*, das "forkt". Nutzen Sie die online System Call Dokumentation.

Das Programm soll den folgenden Output ausgeben, mit konkreten PID Werten für *pid*, *pid_c* und *pid_p*:

```
I'm parent pid of child pid_c
I'm child pid of parent pid_p
```

Entspricht der Output ihren Erwartungen? Wieso?

n|w

File Deskriptoren fork_file_sharing.c TLPI

File Deskriptoren werden bei *fork()* mit *dup()* kopiert:

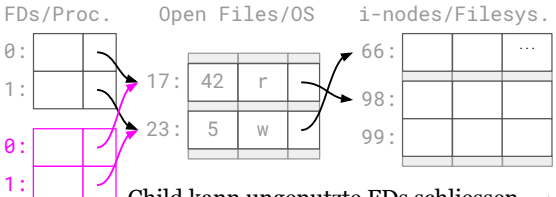

Child kann ungenutzte FDs schliessen.

n|w

Speicher Layout nach *fork()*

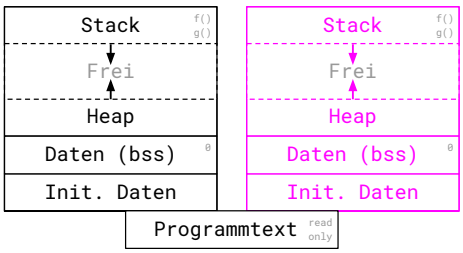

n|w

Speicher Semantik von *fork()*

Virtuellen Speicher kopieren wäre verschwenderisch, denn auf einen *fork()* System Call folgt oft ein *exec()*.

Die Programmtext-Segmente von Parent und Child zeigen auf eine physische Page, die *read-only* ist.

Für Daten-, Heap- und Stack-Segmente des Parents verwendet der Kernel *copy-on-write* Semantik: Erst sind Pages *read-only*, ein Trap bei *write* kopiert sie.

n|w

Prozess Page Table *copy-on-write*

Bei *copy-on-write* wird erst beim *write()* kopiert, die physischen Page Frames werden dann schreibbar:

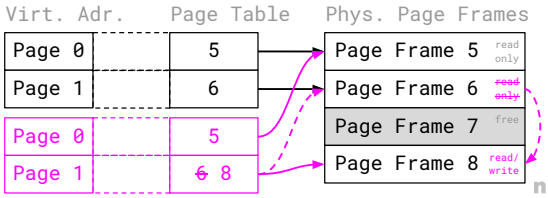

n|w

Funktion in *fork()* wrappen footprint.c[TLPI]

Wenn *f()* Speicher verliert, oder Heap fragmentiert:

```
int pid = fork(); // Child Start, Heap kopiert
if (pid == 0) {
  int status = f(); // problematische Funktion
  exit(status);
} // Child Ende, Ressourcen werden freigegeben
wait(&status); // Wartet auf exit() des Childs
if (status == -1) { … } // Resultat von f()
```

n|w

Race Conditions fork_whos_on_first.c[TLPI]

Nach *fork()* können Parent oder Child zuerst laufen, oder beide parallel, auf Mehrprozessorsystemen:

```
$ ./fork_whos_on_first 10000 > fork.txt
$ ./fork_whos_on_first.count.awk fork.txt
```

Auf Linux kann die Reihenfolge beeinflusst* werden:

```
$ cat /proc/sys/kernel/sched_child_runs_first
```

Child-first kann das Kopieren von Pages minimieren, hier eine Email von Linus Torvalds zum Thema.

n|w

Synchronisation fork_sig_sync.c[TLPI]

Signale helfen, Race Conditions zu verhindern, wenn einer der Prozesse auf den anderen warten muss, z.B. wird hier *SIGUSR1* verschickt, vom Child zum Parent.

Der *sigaction()* Call setzt einen *handler*, wie *signal()*, weil *SIGUSR1* geblockt wurde, bleibt es *pending*.

Mit *sigsuspend()* wird das Signal *SIGUSR1* entblockt und atomar auf Signale gewartet, wie bei *pause()*.

n|w

Hands-on, 45': Signal Masken sync.!c

Schreiben Sie ein Programm *my_sync.c*, das den Code von fork_sig_sync.c[TLPI] wie folgt erweitert:

Der neue Code soll ohne *tlpi_hdr.h* und *curr_time.h* builden und Signal Masken für *blocked* und *pending* Signale ausgeben, dort im Code, wo sich was ändert.

Hinweis: Dokumentation von *sigprocmask()* lesen, *sigpending()* und *printf("%032x", ...)* nutzen.

n|w

Prozess beenden mit *_exit()*

Ein Prozess terminiert *abnormal*, durch ein Signal, oder *normal*, durch Aufruf des *_exit()* System Calls:
`void _exit(int status);`

Das *status* Argument kann via *wait()* gelesen werden, wobei nur die unteren 8 Bits des *int* verfügbar sind.

Ein *status* Wert `!= 0` bedeutet, es gab einen Fehler. Meistens wird der *exit()* Library Call verwendet.

Prozess beenden mit *exit()*

Der *exit()* Library Call macht mehr, als nur *_exit()*:
`void exit(int status);`

Exit Handler, registriert mit *atexit()* und *on_exit()*, werden in umgekehrter Reihenfolge aufgerufen.

Die *stdio* Stream Buffer werden mit *fflush()* geleert.

Der *_exit()* System Call wird mit *status* aufgerufen.

Prozess beenden in *main()*

Ein Prozess kann auch am Ende von *main()* enden:

Explizit, durch *return n* was äquivalent ist zu *exit(n)*, weil die run-time Funktion den Wert in *exit()* steckt.

Oder implizit, indem das Programm unten rausfällt. Das Resultat ist in C89 undefiniert, in C99 *exit(0)*.

Prozess Termination im Detail

Bei normaler und abnormaler Prozess Termination werden die offenen File Deskriptoren geschlossen, und File Locks und Speicher-Mappings freigegeben, sowie weitere Ressourcen im Zusammenhang mit Shared Memory, Semaphoren und Prozessgruppen.

Manchmal will man selber Ressourcen aufräumen, mit mehr Kontrolle, dazu gibt es Exit Handler.

Exit Handler, *atexit()* exit_handlers.c[TLPI]

Die *glibc* Library erlaubt, Exit Handler zu registrieren:

```
int atexit(void (*h)(void)); // != 0 => Error
void cleanup(void) { … } // Beispiel Handler
```

Handler werden in eine Liste eingefügt, und bei *exit()* in umgekehrter Registrationsreihenfolge aufgerufen.

Der Handler bekommt den Exit *status* nicht mit, und sollte selber *exit()* auch nicht nochmal aufrufen.

Exit Handler, *on_exit()*

glibc bietet eine Alternative, Handler zu registrieren:

```
int on_exit(void (*h)(int, void *), void *arg);
void cleanup(int status, void * arg) { … }
```

Das *arg* Argument wird beim Registrieren übergeben, und wird nur vom Handler interpretiert bzw. gecastet.

Die Funktion ist nicht Standard, d.h. nicht portabel.

Im Fehlerfall liefert *on_exit()* einen Wert `!= 0`.

Hands-on, 15': *exit()* fork_stdio_buf.!pdf

Finden Sie heraus, wieso sich in fork_stdio_buf.c[TLPI] der Output dieser beiden Aufrufe unterscheidet:

```
$ ./fork_stdio_buf
$ ./fork_stdio_buf > file && cat file
```

Wieso wird ein Teil des Outputs doppelt ausgegeben?

Wieso wird nur im einen Fall der Output verdoppelt?

Hinweis: Was passiert bei *fork()* im Speicher?

n|w

Prozess Lebensdauer

Parent- und Child-Prozess leben oft verschieden lang:

"Verwaiste" Child-Prozesse bekommen *init* als Parent.

Oder ein Parent ruft *wait()* auf, um den Terminations-Status zu lesen, obwohl der Child-Prozess zu Ende ist.

Der Kernel bewahrt solche, bereits terminierten, aber noch nicht mit *wait()* erwarteten *Zombie*-Prozesse auf.

n|w

Zombie-Prozesse

Der Kernel führt für Zombie-Prozesse eine Liste mit PID, Terminations-Status, und Ressourcen-Statistik. Zombies können mit keinem Signal beendet werden.

Wenn der Parent *wait()* noch aufruft, gibt der Kernel den Status zurück und entfernt den Zombie-Prozess.

Falls der Parent-Prozess *wait()* nicht aufruft, verwaist der Zombie, und der *init*-Prozess ruft *wait()* auf.

n|w

Hands-on, 15': make_zombie.c[TLPI]

Lassen Sie den Beispiel-Code *make_zombie.c* laufen.

Senden Sie dem Zombie-Child ein *SIGKILL* Signal.

Was macht der *system()* Aufruf im Source Code?

Hinweis: <*defunct*> bedeutet Zombie-Prozess.

n|w

Das *SIGCHLD* Signal

Immer wenn ein Child-Prozess terminiert, wird das *SIGCHLD* Signal wird zum Parent-Prozess gesendet.

Ein Handler kann dann *wait()* rechtzeitig aufrufen:

```
int result = signal(SIGCHLD, handle);
void handle(int sig) { int pid = wait(NULL); }
// für > 1 Child, wait() in Loop bis -1, ECHILD
```

Explizites Ignorieren des Signals verhindert Zombies:

```
int result = signal(SIGCHLD, SIG_IGN);
```

n|w

Programm ausführen t_execve.c[TLPI]

Der *execve()* Call ersetzt das laufende Programm:

```
int result = execve(filepath, argv, envp);
```

Das Programm *filepath* startet normal, mit *main()*.

Die PID des ausführenden Prozesses bleibt dieselbe.

Der *return*-Wert kann nur -1 sein, sonst kein *return*.

Zum Beispiel oben braucht's noch envargs.c[TLPI]

n|w

exec() Library Funktionen execlp.c

Von *exec()* gibt es einige Varianten, z.B. *execlp()*:

```
int execlp( // aus der exec() Familie
  const char *file, // statt filepath
  const char *arg, ... /* (char  *) NULL */);
```

Das *l* bedeutet, dass die Argument-Liste "offen" ist:
`execlp("curl", "-v", "tmb.gr", (char *) NULL);`
Das *p* bedeutet, dass das *file* im $PATH gesucht wird, wie in der Shell, wenn man keine '/' verwendet.

n|w

File Deskriptoren und *exec()*

Per default bleiben File Deskriptoren bei *exec()* offen, die Shell nutzt dieses Verhalten, um I/O umzuleiten:
`$ ls /tmp > dir.txt`

Shell forked, Child öffnet *dir.txt* mit *fd = 1*, als *stdout*:
`fd=open(…); dup2(fd, STDOUT_FILENO); close(fd);`

Das Child lässt *ls* laufen mit *exec()*, Output auf *stdout*.

Manche Shell-Kommandos sind eingebaut, z.B. *cd*.

n|w

Das *close-on-exec* Flag closeonexec.c[TLPI]

Manchmal möchte man Files schliessen, vor *exec()*.

Man könnte *close()* aufrufen, aber das Flag ist besser:

```
int flags = fcntl(fd, F_GETFD); // get flags
flags |= FD_CLOEXEC; // add close-on-exec
fcntl(fd, F_SETFD, flags); // set flags
```

So wird ein File Deskriptor nur geschlossen, wenn der *exec()* Aufruf erfolgreich ist, nicht im Fehlerfall.

n|w

Signale und *exec()*

Bei einem exec() wird der Programmtext verworfen.

Dabei verschwinden potentiell auch Signal Handler.

Deshalb setzt der Kernel alle Handler auf *SIG_DFL*, ausser denen, die mit *SIG_IGN* Signale ignorieren.

Die Prozess Signal Maske und das Set von *pending* Signalen bleiben beide intakt während dem *exec()*.

n|w

Shell Kommando ausführen mit *system()*

Die *system()* Funktion kreiert einen Child-Prozess der Shell Kommandos einfach und bequem ausführt:
`int system(const char *cmd); // z.B. "ls | wc"`

Details von fork(), exec(), wait(), and exit() versteckt.

Fehler- und Signal-Handling werden übernommen.

Der *system()* Call nutzt die Shell, wie "von Hand".

n|w

Hands-on, 15': simple_system.!c[TLPI]

Implementieren Sie eine eigene *system()* Funktion.

Nutzen Sie dazu das *sh* Kommando mit Argument *-c*:
`$ sh -c "ls | wc"`

Vereinfachung: Gerüst von *my_system.c* im Repo.

n|w

Signals und *system()*

system.c TLPI

Das Beispiel *system.c* zeigt eine robustere Variante.

Der Caller sollte *SIGINT* und *SIGQUIT* während dem Kommando mit *SIG_IGN* behandeln, das Child mit *SIG_DFT*, um verwirrendes Verhalten zu vermeiden.

Beim Warten wird hier *waitpid()* benutzt, um auf den Child-Prozess zu warten, den wir gestartet haben.

n|w

Warten mit *waitpid()*

child_status.c TLPI

Der *waitpid()* Call erlaubt, auf einen konkreten Child-Prozess zu warten. Im Gegensatz zu *wait()* blockiert der Call nicht, wenn noch kein Child beendet wurde:

```
pid_t waitpid(pid_t pid, // Child PID, 0, …
  int *status, // Makro WIFEXITED(status), …
  int options); // WNOHANG => non-blocking, …
```

Beispiel *child_status* verwendet print_wait_status.c:

```
$ ./child_status 23 # exit() mit Status 23
```

n|w

Selbststudium, 3h: Topic

Als Vorbereitung auf die nächste Lektion, lesen Sie https://computing.llnl.gov/tutorials/pthreads/ bis *Pthread Excercice 1*.

Falls Zeit übrig bleibt, beginnen Sie mit Repetieren der bisherigen Lektionen für das Assessment.

n|w

Feedback?

Gerne im Slack oder an thomas.amberg@fhnw.ch

Programmierfragen am besten schriftlich.

Sprechstunde auf Voranmeldung.

Slides, Code & Hands-on: tmb.gr/syspr-5